

# INFORME TÉCNICO

## SATISFACCIÓN DE NIÑOS Y ABUELOS

Por:

Daniel Espinal Mosquera

Juan Sebastián Falcón

Juan F. Peña Tamayo

Brayan M. Ortiz Fajardo

Thalea Marina Hesse



**Universidad Nacional de Colombia**  
**Sede Medellín**

# Introducción

La satisfacción de la vida y la felicidad varía entre países [7] y juegan un papel importante en el desarrollo de un país. Sin embargo, no se logró determinar documentación o estudios relacionados sobre cómo se pueden predecir estos factores en Colombia dados unos parámetros. Por tal motivo, se propone el planteamiento, desarrollo, análisis y posterior productización de un modelo con el cual se busca predecir la satisfacción de niños y abuelos. Para lograr esto, se toma como base una encuesta realizada por el DANE en el 2020: Colombia - Encuesta Nacional de Calidad de Vida - ECV 2020. Esta investigación, según el DANE “Busca cuantificar y caracterizar las condiciones socioeconómicas de los hogares colombianos, con el fin de obtener la información necesaria para la actualización de indicadores sociales a nivel de viviendas, hogares y personas, y para la definición de políticas que permitan diseñar y ejecutar planes sociales.” (Metodología ECV, 2009, p.17)

La estructura del estudio se planteó de la siguiente manera: se hizo una búsqueda exhaustiva sobre documentación para determinar cuáles de las variables que se tienen afectan de manera significativa la satisfacción. Después se planteó un modelo general, sin embargo al revisar las correlaciones entre las variables predictoras se decidió partir ese modelo general en tres sub-modelos: satisfacción de salud, seguridad y trabajo. Para cada uno de estos también se realizó la búsqueda de documentación al respecto. Adicionalmente, se creó una página web para poder interactuar con los modelos. Finalmente, se obtuvieron los resultados y plantearon las conclusiones.

## Planteamiento del Problema

El Instituto Colombiano de Bienestar Familiar es una entidad que trabaja por la prevención y protección integral de la primera infancia, la niñez, la adolescencia y el bienestar general de las familias en Colombia, llegando a millones de colombianos mediante sus programas, estrategias y servicios de atención. En el marco de los objetivos de esta institución se encontró que el ICBF actualmente no cuenta con una herramienta para conocer en prospectiva, y de forma adecuada y efectiva la satisfacción general de vida tanto de niños como de adultos en la tercera edad. Es para ellos de vital importancia conocer esta información pues es un indicador fundamental a tener en cuenta a la hora de crear programas preventivos y de protección que tienen como objetivo el mejoramiento de vida de la población destinataria. Por esto se busca implementar en el ICBF tanto los 3 sub-modelos como el modelo de satisfacción general, para que sea usado por la institución en pro de mejorar futuros planeamientos en todo proyecto social que involucre niños y adultos de la tercera edad como población objetivo.

## Justificación

### Niños

En primera instancia se planteó tomar a los niños en dos grupos, uno como aquellos pertenecientes a la primera infancia (0 a 5 años) y otro con aquellos niños con edad entre 6 y 12 años. Sin embargo, luego se decidió que tomaríamos como niño la definición integrada en el código de infancia y adolescencia, donde se expone que “Para todos los efectos de esta ley son sujetos titulares de derechos todas las personas menores de 18 años. Sin perjuicio de lo establecido en el artículo 34 del Código Civil, se entiende por niño o niña las personas entre los 0 y los 12 años, y por adolescente las personas entre 12 y 18 años de edad”(Artículo 3).

Una vez adoptada esta definición se analizó cuántas observaciones de la ECV cumplían esta condición, resultando en un total de 56128 niños.

### Abuelos

Para los abuelos, al igual que con los niños, se pensó inicialmente en tomar un rango de edad que tomara la definición popular de este colectivo, los adultos de la tercera edad (mayores de 60 años). Sin embargo, luego planteamos que debíamos tener en cuenta cuál es la definición literal de abuelo, y mediante un sistema de

grafos logramos determinar el numero de hombres y mujeres que tenian un nieto. Filtrandolos por su rango edad.

Mayor a 60 años	1467
Menor a 60 años	1049

Se observa que con la definicion inicial estabamos omitiendo un total de 1049 observaciones, ademas, se observa que los abuelos resgitrados en la base de datos son relativamente pocos pues solo representan el x % del total de personas.

Ante esta situación tomamos la desicion de ...

## Modelos Predictivos

Inicialmente, se intentó englobar en un modelo a los abuelos y niños con el fin de predecir la satisfacción. Sin embargo, como lo ilustra la Figura 1, las variables objetivas que se seleccionaron no fueron respondidas, en su mayoría, por niños. Este comportamiento se asemeja con los resultados encontrados en [7], donde se puede observar que los abuelos y niños tienen diferentes definiciones de satisfacción y, por ende, diferentes factores que la influyen. Por esta razón, se decidió trabajar de forma independiente los modelos para los niños y abuelos.

	P1897	P1896	P1898	P1899	P1895	P2059
<b>Clasificación</b>						
<b>3ra_edad</b>	36817	36817	36817	36817	36817	13373
<b>niño</b>	0	0	0	0	0	0
<b>otro</b>	164139	164139	164139	164139	164139	80603

Figura 1: Niños no responden las preguntas más significativas

## Modelos Predictivos en Abuelos

### Selección de Variables

De [1] y [2] se obtuvieron las variables para el modelo general. Se realizó un mapeo con las que se tenían en la base de datos del DANE y se eligieron las siguientes:

##	V1	V2	V3
## 1	NIVEL_DE_EDUCACION	SEXO	SALUD_AUTOPERCIBIDA
## 2	ESTADO_CIVIL	ETNIA	INGRESO_AUTOPERCIBIDO
## 3	SEGURIDAD_AUTOPERCIBIDA	TRABAJO_AUTOPERCIBIDO	SATISFACCION
## 4	I_HOGAR	PERCAPITA	COND_VIDA_DEL_HOGAR

Cada una de estas variables mostraron correlación en los estudios realizados sobre factores que influyen en la satisfacción de la vida en abuelos. En [2] también mencionan variables que involucran relaciones sociales, sin embargo en la base de datos no se logró de terminar alguna asociación lógica para este tipo de variables.


## Satisfacción de la Vida en General

### Análisis Descriptivo

Según la tabla anterior las variables que preguntan directamente por la satisfacción no son respondidas por los niños, por lo tanto se decide abordar y desarrollar modelos por separado para niños y abuelos.

### Matriz de Correlaciones

Para empezar la selección de posibles variables objetivo y predictoras de las escogidas anteriormente se desarrolla el siguiente gráfico de correlación:



Se evalúa la posibilidad de establecer como posible variable objetivo la satisfacción, esta tiene una buena correlación con las variables de satisfacción pero no con el resto, por lo tanto es posible que no tenga mucho sentido predecir la satisfacción general de un abuelo a partir de todas estas variables. Con base en lo anterior se evalúa la implementación de varios modelos, uno por cada variable de satisfacción.

### KNN

```
##      Y KNN_Predict
## 2      7          10
## 4      8          10
## 7      9          10
## 13     10         10
## 20      5          10
## 22      5          10
```

### Regresion con lm

```
##
```

```
## Call:
## lm(formula = Y ~ ., data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9.7241 -0.7557  0.0388  0.7737  7.1464
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  3.859374   0.034469 111.967 < 2e-16 ***
## X1           0.296308   0.002969  99.805 < 2e-16 ***
## X2           0.204260   0.002976  68.643 < 2e-16 ***
## X3           0.017679   0.003018   5.858 4.7e-09 ***
## X4          -0.264695   0.008683 -30.486 < 2e-16 ***
## X5           0.131768   0.002526  52.169 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.448 on 82163 degrees of freedom
## Multiple R-squared:  0.3965, Adjusted R-squared:  0.3964
## F-statistic: 1.079e+04 on 5 and 82163 DF,  p-value: < 2.2e-16

##      Y Y_Predict
## 2    7  7.913474
## 4    8  7.617167
## 7    9  8.739471
## 13  10  7.535134
## 20    5  4.988081
## 22    5  4.988081

##      1
## 5.015333
```


## Satisfacción en la Salud

Según (PONER BIBLIOGRAFÍA) se seleccionan las siguientes variables como posibles predictores de la satisfacción de la Salud de los abuelos:

- AFILIADO (p6090)
- PAGO\_EPS (p8551)
- CALIDAD\_PRESTADOR (p6181)
- ESTADO\_SALUD (p6127)
- TIPO\_PAGO (p6115)
- REGIMEN (P6100)
- ENFERMEDAD\_CRONICA (P1930)

## Análisis Descriptivo

### Matriz de Correlaciones



### Regresion con lm

```
##      SATISFACCION CALIDAD_EPS ESTADO_SALUD ESTRATO REGIMEN ENFERMEDAD_CRONICA
## 1           8         2           2         3         0           2
## 3          10         2           2         3         0           2
## 5           7         2           3         3         0           2
## 11          1         1           4         3         2           1
## 26          3         3           3         3         0           1
## 29          4         2           3         3         2           1

##
## Call:
## lm(formula = SATISFACCION ~ ., data = train_salud)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9.1444 -1.0243  0.1668  1.1887  5.7506
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   10.420753   0.079567  130.968 < 2e-16 ***
## CALIDAD_EPS    -0.157173   0.022567  -6.965 3.36e-12 ***
## ESTADO_SALUD   -1.426687   0.019721 -72.343 < 2e-16 ***
## ESTRATO         0.021954   0.008358   2.627 0.00863 **
## REGIMEN        -0.157869   0.012427 -12.704 < 2e-16 ***
```

```
## ENFERMEDAD_CRONICA 0.300661 0.024138 12.456 < 2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.848 on 27607 degrees of freedom
## Multiple R-squared: 0.2271, Adjusted R-squared: 0.2269
## F-statistic: 1622 on 5 and 27607 DF, p-value: < 2.2e-16

## SATISFACCION Y_Predict
## 2 7 7.920215
## 4 7 6.192868
## 25 9 7.763042
## 41 8 7.604477
## 59 4 6.493529
## 63 10 7.761650

## 'data.frame': 27613 obs. of 6 variables:
## $ SATISFACCION : int 8 10 7 1 3 4 9 5 6 6 ...
## $ CALIDAD_EPS : int 2 2 2 1 3 2 2 2 2 2 ...
## $ ESTADO_SALUD : int 2 2 3 4 3 3 2 3 2 2 ...
## $ ESTRATO : int 3 3 3 3 3 3 3 3 3 3 ...
## $ REGIMEN : num 0 0 0 2 0 2 2 0 0 2 ...
## $ ENFERMEDAD_CRONICA: int 2 2 2 1 1 1 2 2 2 2 ...
```


### Satisfacción sobre el Nivel de Seguridad

Según (PONER BIBLIOGRAFÍA) se seleccionan las siguientes variables como posibles predictores de la satisfacción de la seguridad de los abuelos:

- ESTADO\_CIVIL (P5502)
- SEXO (P6020')
- ESTRATO (P8520S1A1)
- NIVEL\_DE\_SEGURIDAD (P9010)
- CONDICIONES\_DE\_VIDA\_HOGAR (P9030)
- ES\_CAMPESENO (P2059)
- CAI P1913S5
- ROBO P9025S2
- OTRO\_DELITO P9025S1
- LEE\_ESCRIBE (P6160)

### Análisis Descriptivo

## Matriz de Correlaciones Pearson



## Correlaciones Polychoric

Para tener mayor certeza sobre la relación entre variables, se hace uso del método Polychoric y se obtuvieron los siguientes resultados:

```
## ESTADO_CIVIL SEXO ESTRATO NIVEL_DE_SEGURIDAD
## 1 0.05245109 0.005751776 0.04578935 -0.3815545
## CONDICIONES_DE_VIDA_HOGAR ES_CAMPEINO CAI ROBO OTRO_DELITO
## 1 -0.1919623 -0.03652896 0.01510149 0.239952 0.1882934
## LEE_ESCRIBE
## 1 -0.0763971
```

Por tal motivo, se decide eliminar las variables SEXO, ESTRATO, ES\_CAMPEINO y CAI ya que no presentan un correlación significativa con la variable objetivo.

## Regresion con lm

```
##
## Call:
## lm(formula = SATISFACCION ~ ., data = train_seguridad)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8.1740 -0.8803  0.1944  1.3802  4.9497
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
```



```
## (Intercept)          9.333577    0.130701   71.412   <2e-16 ***
## ESTADO_CIVIL         0.037349    0.004186    8.922   <2e-16 ***
## NIVEL_DE_SEGURIDAD   -1.423063    0.022829  -62.336   <2e-16 ***
## CONDICIONES_DE_VIDA_HOGAR -0.405692    0.011283  -35.956   <2e-16 ***
## OTRO_DELITO          0.036470    0.056879    0.641    0.521
## ROBO                 0.335002    0.029988   11.171   <2e-16 ***
## LEE_ESCRIBE         -0.185847    0.017446  -10.653   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.918 on 80538 degrees of freedom
## Multiple R-squared:  0.09038,    Adjusted R-squared:  0.09031
## F-statistic: 1334 on 6 and 80538 DF,  p-value: < 2.2e-16

## SATISFACCION Y_Predict
## 2          8  7.325230
## 4         10  7.399928
## 7          8  7.325230
## 13        10  7.880318
## 38         4  7.768271
## 40         4  7.768271
```

### Satisfacción en el Trabajo

Según (PONER BIBLIOGRAFÍA) se seleccionan las siguientes variables como posibles predictores de la satisfacción en el trabajo de los abuelos:

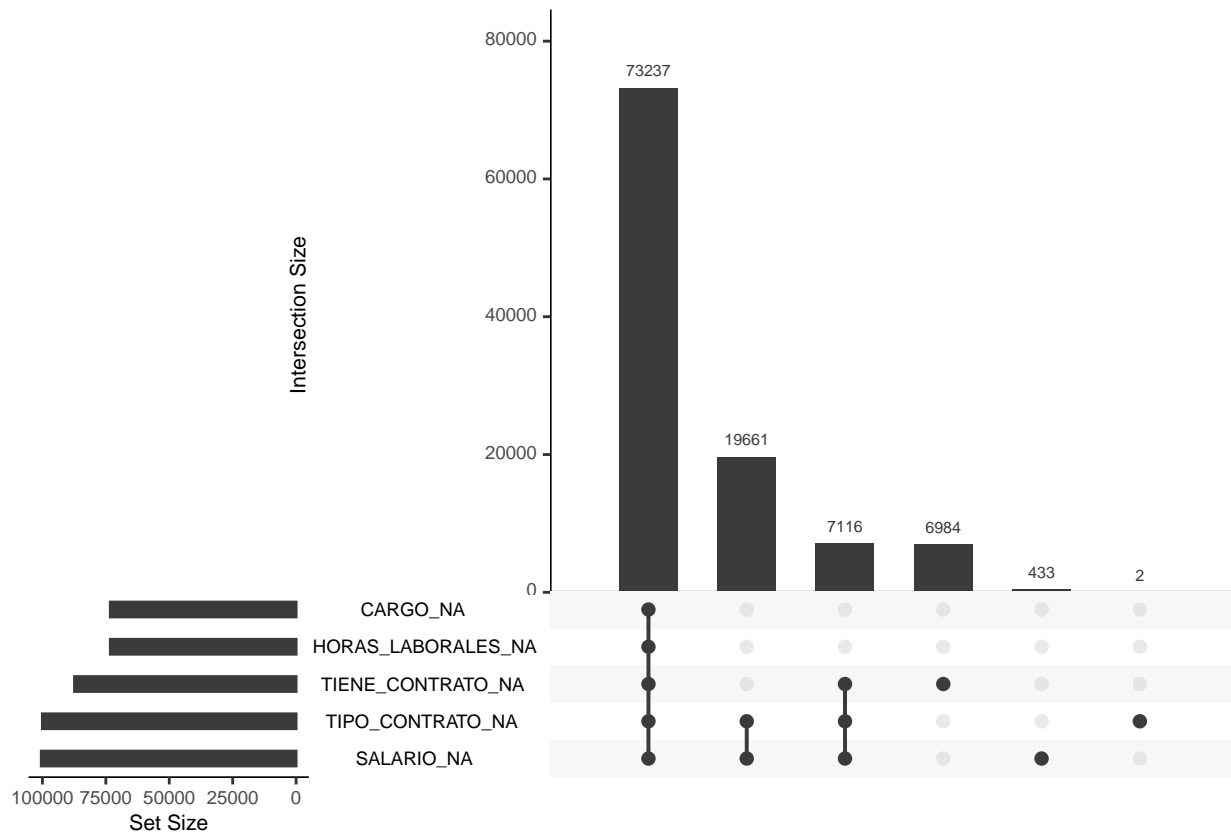
- SEXO (P6020')
- CARGO (P6435)
- TIENE\_CONTRATO (P6440)
- TIPO\_CONTRATO (P6460)
- SALARIO (P8624)
- HORAS\_LABORALES (P415)
- RECIBIO\_PRIMAS (P8631)
- RECIBIO\_PENSIONES (P8642)

### Análisis Descriptivo

**Datos Faltantes** Para este dataframe se tiene la siguiente cantidad de abuelos:

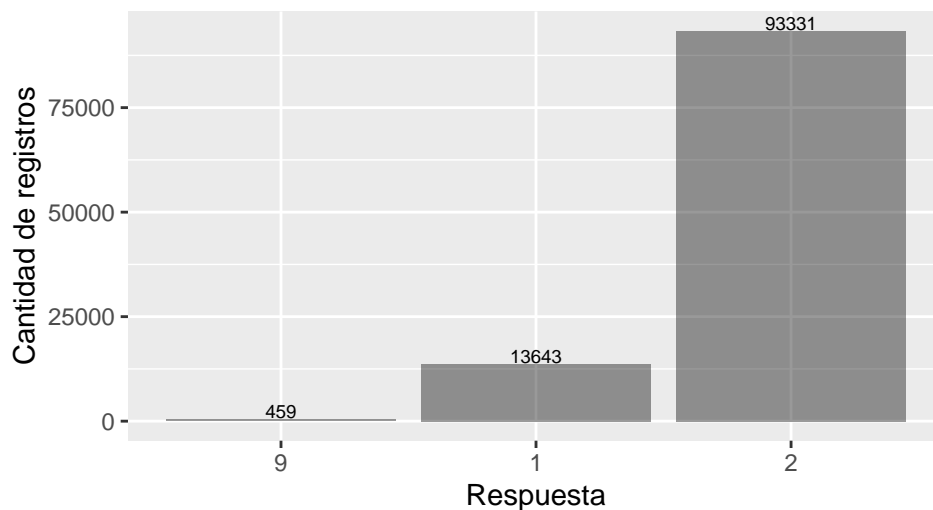
```
## Cantidad de Abuelos
## 1          107433
```

Sin embargo, si se observa la cantidad de abuelos que respondieron a las preguntas seleccionadas:



se puede determinar que la mayoría de estos no respondieron a las preguntas que se les hicieron sobre el trabajo. Este mismo procedimiento se repitió con variables diferentes, pero no se obtuvieron resultados distintos a los presentados. Por tal motivo, se decide no realizar un modelo de predicción para la satisfacción del trabajo en los abuelos. En primera instancia se pensó que este comportamiento se debía a que la mayoría de los abuelos estaban pensionados, pero si se observan los abuelos pensionados:

### ¿Recibe pensión?



la gran mayoría de estos respondieron que no recibían algún tipo de pensión (2). Por tanto, se puede inferir que la mayoría de los abuelos no trabajan y tampoco reciben pensión, es decir, viven dependientes de sus familiares.

## Modelos Predictivos en Niños

```
# los datos:
ninos <- read.csv2("Datos/datos_ninos.csv", header=TRUE, dec=".", encoding="UTF-8")
```

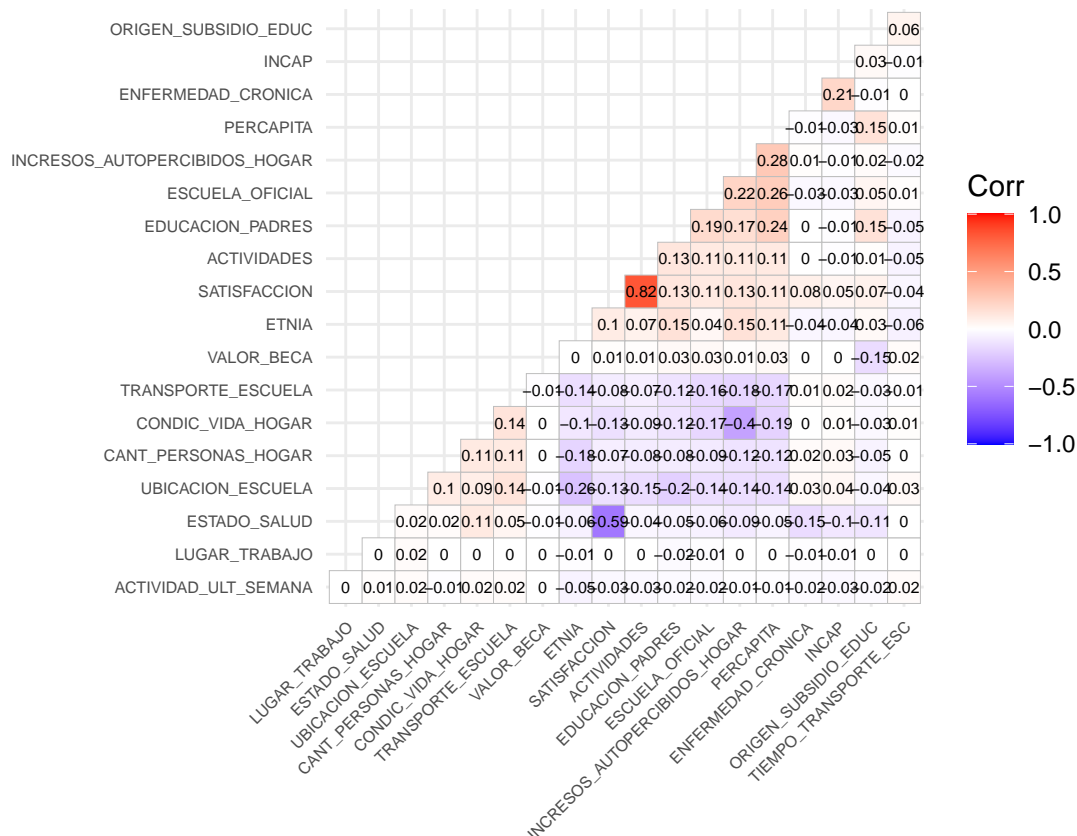
### Correlaciones

```
corr_ninos <- ninos %>% select(SATISFACCION, ESTADO_SALUD, ACTIVIDADES, ETNIA,
                              CONDIC_VIDA_HOGAR, INCRESOS_AUTOPERCIBIDOS_HOGAR,
                              PERCAPITA, CANT_PERSONAS_HOGAR, ESCUELA_OFICIAL,
                              VALOR_BECA, ORIGEN_SUBSIDIO_EDUC, UBICACION_ESCUELA,
                              TRANSPORTE_ESCUELA, TIEMPO_TRANSPORTE_ESC,
                              EDUCACION_PADRES ,ACTIVIDAD_ULT_SEMANA,
                              LUGAR_TRABAJO, ENFERMEDAD_CRONICA, INCAP)

M = cor(corr_ninos, use = "pairwise.complete.obs")

M[is.na(M)]=0

ggcorrplot(M, hc.order = TRUE, type = "lower", lab = TRUE, tl.cex = 6,
           pch.col = "red", lab_size = 2)
```



Los datos para niños:

```
df_ninos <- ninos %>% select(INCAP, SATISFACCION,
                              PERCAPITA, INCRESOS_AUTOPERCIBIDOS_HOGAR,
                              UBICACION_ESCUELA, EDUCACION_PADRES,
```

```

CONDIC_VIDA_HOGAR, TIEMPO_TRANSPORTE_ESC, HORAS_TRABAJO)

df_ninos['ETNIA'] = as.factor(ninos[, 'ETNIA'])

df_ninos['VIVE_CON_PADRE'] = factor(ninos[, 'VIVE_CON_PADRE'], labels = c(TRUE,
                                                                    FALSE,
                                                                    'Muerto'))

df_ninos['VIVE_CON_MADRE'] = factor(ninos[, 'VIVE_CON_MADRE'], labels = c(TRUE,
                                                                    FALSE,
                                                                    'Muerto'))

df_ninos['ESCUELA_OFICIAL'] = factor(ninos[, 'ESCUELA_OFICIAL'], labels = c('Oficial',
                                                                    'conSubstituto',
                                                                    'SinSubstituto'))

df_ninos['TRANSPORTE_ESCUELA'] = addNA(factor(ninos[, 'TRANSPORTE_ESCUELA'],
                                              labels = c('Carro', 'escolar', 'público',
                                              'pie', 'Bicicleta', 'Caballo',
                                              'canoa', 'Otro'))))

df_ninos['ENFERMEDAD_CRONICA'] = addNA(factor(ninos[, 'ENFERMEDAD_CRONICA'],
                                              labels = c(TRUE, FALSE)))

df_ninos['ACTIVIDAD_ULT_SEMANA'] = addNA(factor(ninos[, 'ACTIVIDAD_ULT_SEMANA'],
                                              labels = c('Trabajando', 'Buscando',
                                              'Estudiando', 'Oficios_hogar',
                                              'Incapacitado trabajar', 'Otra'))))

df_ninos['LUGAR_TRABAJO'] = addNA(factor(ninos[, 'LUGAR_TRABAJO'],
                                          labels = c('no trabajo', 'la vivienda',
                                          'otra vivienda', 'Puerta',
                                          'calle', 'oficina', 'campo',
                                          'obra'))))

head(df_ninos)

```

```

##      INCAP SATISFACCION PERCAPITA INCRESOS_AUTOPERCIBIDOS_HOGAR UBICACION_ESCUELA
## 1      32           31  694500.0                      2              1
## 2      32           25  265083.3                      2              1
## 3      32           34  300000.0                      2              1
## 4      32           25  759078.5                      1              1
## 5      32           31  954500.0                      2              1
## 6      32           31  600000.0                      2              1
##      EDUCACION_PADRES CONDIC_VIDA_HOGAR TIEMPO_TRANSPORTE_ESC HORAS_TRABAJO ETNIA
## 1              2              2              5              0      6
## 2              4              2             30              0      6
## 3             NA              2             15              0      6
## 4              3              2             10              0      6
## 5             NA              3             15              0      6
## 6             NA              2             10              0      6
##      VIVE_CON_PADRE VIVE_CON_MADRE ESCUELA_OFICIAL TRANSPORTE_ESCUELA
## 1             FALSE             FALSE      Oficial           pie
## 2             FALSE              TRUE      Oficial           Carro

```

```
## 3      TRUE      TRUE SinSubstito escolar
## 4      FALSE     TRUE SinSubstito Carro
## 5      TRUE      TRUE SinSubstito pie
## 6      TRUE      TRUE SinSubstito pie
## ENFERMEDAD_CRONICA ACTIVIDAD_ULT_SEMANA LUGAR_TRABAJO
## 1      FALSE      Estudiando no trabajo
## 2      FALSE      Estudiando no trabajo
## 3      FALSE      Estudiando no trabajo
## 4      FALSE      Estudiando no trabajo
## 5      FALSE      Estudiando no trabajo
## 6      FALSE      Estudiando no trabajo
```

## Resultados del entrenamiento

- Separación de los datos en entrenamiento y prueba

```
datos1 <- sample(2, nrow(df_ninos),
                 replace = TRUE,
                 prob = c(0.75, 0.25))

train <- df_ninos[datos1 == 1,]
test <- df_ninos[datos1 == 2,]
```

- Modelo de árbol de decisión

```
ctreeNiños <- ctree(formula = SATISFACCION ~ ., data=train,
                    controls = ctree_control(mincriterion = 0.7))

save(file="App/data/modeloSatisfaccionNiños.RData",
     list=c("ctreeNiños"))
```

```
png(file = "App/www/decision_tree_niños.png", width = 6000, height = 3000, )
plot(ctreeNiños)
dev.off()
```

```
## pdf
## 2
```

```
ctreeNiños
```

```
##
## Conditional inference tree with 83 terminal nodes
##
## Response: SATISFACCION
## Inputs: INCAP, PERCAPITA, INCRESOS_AUTOPERCIBIDOS_HOGAR, UBICACION_ESCUELA, EDUCACION_PADRES, CONDI
## Number of observations: 23500
##
## 1) INCRESOS_AUTOPERCIBIDOS_HOGAR <= 1; criterion = 1, statistic = 387.565
## 2) ENFERMEDAD_CRONICA == {FALSE}; criterion = 1, statistic = 150.524
## 3) UBICACION_ESCUELA <= 2; criterion = 1, statistic = 134.596
## 4) TRANSPORTE_ESCUELA == {Carro, escolar, pie, Caballo}; criterion = 1, statistic = 70.921
## 5) PERCAPITA <= 85555.56; criterion = 1, statistic = 40.862
## 6) ETNIA == {5, 6}; criterion = 1, statistic = 27.373
## 7) VIVE_CON_MADRE == {TRUE, Muerto}; criterion = 0.957, statistic = 11.816
## 8) VIVE_CON_MADRE == {Muerto}; criterion = 0.895, statistic = 7.293
## 9)* weights = 7
## 8) VIVE_CON_MADRE == {TRUE}
```

```

##          10)* weights = 593
##      7) VIVE_CON_MADRE == {FALSE}
##          11)* weights = 95
##      6) ETNIA == {1, 4}
##          12) CONDIC_VIDA_HOGAR <= 2; criterion = 1, statistic = 23.549
##          13) TRANSPORTE_ESCUELA == {pie}; criterion = 0.925, statistic = 10.661
##          14)* weights = 133
##          13) TRANSPORTE_ESCUELA == {Carro, escolar}
##          15)* weights = 14
##          12) CONDIC_VIDA_HOGAR > 2
##          16) PERCAPITA <= 12500; criterion = 0.919, statistic = 7.784
##          17)* weights = 43
##          16) PERCAPITA > 12500
##          18)* weights = 109
##      5) PERCAPITA > 85555.56
##          19) EDUCACION_PADRES <= 1; criterion = 1, statistic = 23.783
##          20) ESCUELA_OFICIAL == {SinSubstituto}; criterion = 1, statistic = 25.995
##          21)* weights = 125
##          20) ESCUELA_OFICIAL == {Oficial, conSubstituto}
##          22) INCAP <= 30; criterion = 0.952, statistic = 16.629
##          23)* weights = 65
##          22) INCAP > 30
##          24) ETNIA == {3, 6}; criterion = 0.941, statistic = 15.067
##          25) ACTIVIDAD_ULT_SEMANA == {Estudiando, Otra}; criterion = 0.868, statistic = 11.0
##          26)* weights = 2423
##          25) ACTIVIDAD_ULT_SEMANA == {Oficios_hogar, NA}
##          27) ACTIVIDAD_ULT_SEMANA == {NA}; criterion = 0.863, statistic = 7.423
##          28)* weights = 486
##          27) ACTIVIDAD_ULT_SEMANA == {Oficios_hogar}
##          29) PERCAPITA <= 248000; criterion = 0.749, statistic = 5.928
##          30)* weights = 20
##          29) PERCAPITA > 248000
##          31)* weights = 8
##          24) ETNIA == {1, 5}
##          32) ESCUELA_OFICIAL == {Oficial}; criterion = 0.999, statistic = 16.048
##          33) TIEMPO_TRANSPORTE_ESC <= 15; criterion = 0.998, statistic = 14.618
##          34)* weights = 652
##          33) TIEMPO_TRANSPORTE_ESC > 15
##          35) VIVE_CON_PADRE == {TRUE, Muerto}; criterion = 0.997, statistic = 17.203
##          36) UBICACION_ESCUELA <= 1; criterion = 0.737, statistic = 5.396
##          37) TIEMPO_TRANSPORTE_ESC <= 50; criterion = 0.83, statistic = 7.137
##          38)* weights = 104
##          37) TIEMPO_TRANSPORTE_ESC > 50
##          39)* weights = 14
##          36) UBICACION_ESCUELA > 1
##          40) ETNIA == {1}; criterion = 0.987, statistic = 11.087
##          41) TRANSPORTE_ESCUELA == {Carro, pie}; criterion = 0.994, statistic = 1
##          42)* weights = 38
##          41) TRANSPORTE_ESCUELA == {escolar}
##          43)* weights = 8
##          40) ETNIA == {5}
##          44)* weights = 16
##          35) VIVE_CON_PADRE == {FALSE}
##          45)* weights = 77

```

```

##          32) ESCUELA_OFICIAL == {conSubstituto}
##          46)* weights = 11
##      19) EDUCACION_PADRES > 1
##          47)* weights = 1301
##  4) TRANSPORTE_ESCUELA == {público, Bicicleta, canoa, Otro, NA}
##      48) CONDIC_VIDA_HOGAR <= 1; criterion = 1, statistic = 21.092
##          49)* weights = 66
##      48) CONDIC_VIDA_HOGAR > 1
##          50) INCAP <= 30; criterion = 1, statistic = 21.946
##          51)* weights = 49
##      50) INCAP > 30
##          52) ETNIA == {2, 4, 5, 6}; criterion = 0.995, statistic = 23.164
##          53) TRANSPORTE_ESCUELA == {público, Bicicleta, Otro, NA}; criterion = 0.883, statistic = 21.092
##          54) UBICACION_ESCUELA <= 1; criterion = 0.724, statistic = 6.32
##          55)* weights = 1769
##          54) UBICACION_ESCUELA > 1
##          56) TRANSPORTE_ESCUELA == {público, Bicicleta, NA}; criterion = 0.708, statistic = 6.32
##          57)* weights = 366
##          56) TRANSPORTE_ESCUELA == {Otro}
##          58)* weights = 28
##          53) TRANSPORTE_ESCUELA == {canao}
##          59) ETNIA == {5}; criterion = 0.994, statistic = 12.703
##          60)* weights = 31
##          59) ETNIA == {6}
##          61)* weights = 24
##          52) ETNIA == {1, 3}
##          62) INCAP <= 31; criterion = 0.822, statistic = 6.641
##          63)* weights = 9
##          62) INCAP > 31
##          64)* weights = 317
##  3) UBICACION_ESCUELA > 2
##      65) ETNIA == {3, 4, 6}; criterion = 1, statistic = 38.644
##      66) TIEMPO_TRANSPORTE_ESC <= 70; criterion = 1, statistic = 20.331
##          67)* weights = 1888
##      66) TIEMPO_TRANSPORTE_ESC > 70
##          68)* weights = 17
##      65) ETNIA == {1, 2, 5}
##      69) TRANSPORTE_ESCUELA == {público, Bicicleta, Caballo, Otro, NA}; criterion = 1, statistic = 26.044
##      70) TRANSPORTE_ESCUELA == {Bicicleta}; criterion = 1, statistic = 26.044
##          71)* weights = 16
##      70) TRANSPORTE_ESCUELA == {público, Caballo, Otro, NA}
##          72) CONDIC_VIDA_HOGAR <= 2; criterion = 1, statistic = 19.414
##          73) TRANSPORTE_ESCUELA == {público, NA}; criterion = 0.878, statistic = 9.5
##          74)* weights = 128
##          73) TRANSPORTE_ESCUELA == {Otro}
##          75)* weights = 7
##          72) CONDIC_VIDA_HOGAR > 2
##          76) ETNIA == {1}; criterion = 0.717, statistic = 5.307
##          77)* weights = 49
##          76) ETNIA == {5}
##          78)* weights = 26
##      69) TRANSPORTE_ESCUELA == {Carro, escolar, pie, canoa}
##      79) ESCUELA_OFICIAL == {SinSubstituto}; criterion = 1, statistic = 24.889
##          80)* weights = 15

```

```

##          79) ESCUELA_OFICIAL == {Oficial, conSubstituto}
##          81) ACTIVIDAD_ULT_SEMANA == {Estudiando, Otra, NA}; criterion = 0.992, statistic = 17.85
##          82) VIVE_CON_MADRE == {TRUE, Muerto}; criterion = 0.937, statistic = 11.013
##          83) EDUCACION_PADRES <= 0; criterion = 0.835, statistic = 6.431
##          84)* weights = 121
##          83) EDUCACION_PADRES > 0
##          85)* weights = 1021
##          82) VIVE_CON_MADRE == {FALSE}
##          86) VIVE_CON_PADRE == {FALSE}; criterion = 0.902, statistic = 10.103
##          87)* weights = 66
##          86) VIVE_CON_PADRE == {TRUE, Muerto}
##          88)* weights = 44
##          81) ACTIVIDAD_ULT_SEMANA == {Oficios_hogar}
##          89) TIEMPO_TRANSPORTE_ESC <= 45; criterion = 0.798, statistic = 16.446
##          90)* weights = 57
##          89) TIEMPO_TRANSPORTE_ESC > 45
##          91)* weights = 8
## 2) ENFERMEDAD_CRONICA == {TRUE}
##    92) EDUCACION_PADRES <= 2; criterion = 0.989, statistic = 12.785
##    93) INCAP <= 30; criterion = 0.919, statistic = 10.843
##    94)* weights = 55
##    93) INCAP > 30
##    95) ESCUELA_OFICIAL == {conSubstituto, SinSubstituto}; criterion = 0.995, statistic = 15.955
##    96)* weights = 18
##    95) ESCUELA_OFICIAL == {Oficial}
##    97)* weights = 246
##    92) EDUCACION_PADRES > 2
##    98)* weights = 18
## 1) INCRESOS_AUTOPERCIBIDOS_HOGAR > 1
##    99) CONDIC_VIDA_HOGAR <= 1; criterion = 1, statistic = 310.312
##    100) INCRESOS_AUTOPERCIBIDOS_HOGAR <= 2; criterion = 0.992, statistic = 12.357
##    101) EDUCACION_PADRES <= 1; criterion = 0.904, statistic = 8.242
##    102) ENFERMEDAD_CRONICA == {FALSE}; criterion = 0.796, statistic = 9.134
##    103)* weights = 103
##    102) ENFERMEDAD_CRONICA == {TRUE}
##    104)* weights = 10
##    101) EDUCACION_PADRES > 1
##    105) VIVE_CON_MADRE == {FALSE}; criterion = 0.984, statistic = 13.843
##    106)* weights = 29
##    105) VIVE_CON_MADRE == {TRUE, Muerto}
##    107)* weights = 533
##    100) INCRESOS_AUTOPERCIBIDOS_HOGAR > 2
##    108) ETNIA == {3, 6}; criterion = 0.825, statistic = 10.958
##    109)* weights = 204
##    108) ETNIA == {1, 5}
##    110)* weights = 12
##    99) CONDIC_VIDA_HOGAR > 1
##    111) UBICACION_ESCUELA <= 2; criterion = 1, statistic = 134.429
##    112) PERCAPITA <= 330083.3; criterion = 1, statistic = 49.352
##    113) TIEMPO_TRANSPORTE_ESC <= 20; criterion = 1, statistic = 44.722
##    114) TRANSPORTE_ESCUELA == {Carro, público, pie, Caballo, Otro, NA}; criterion = 1, statis
##    115) CONDIC_VIDA_HOGAR <= 2; criterion = 0.861, statistic = 11.812
##    116) EDUCACION_PADRES <= 1; criterion = 0.731, statistic = 7.555
##    117)* weights = 1913

```



```

##          116) EDUCACION_PADRES > 1
##          118) ENFERMEDAD_CRONICA == {FALSE}; criterion = 0.768, statistic = 10.529
##          119)* weights = 539
##          118) ENFERMEDAD_CRONICA == {TRUE}
##          120)* weights = 10
##      115) CONDIC_VIDA_HOGAR > 2
##          121)* weights = 618
##      114) TRANSPORTE_ESCUELA == {escolar, Bicicleta, canoa}
##          122) PERCAPITA <= 143333.3; criterion = 0.853, statistic = 6.66
##          123) CONDIC_VIDA_HOGAR <= 2; criterion = 0.788, statistic = 5.94
##          124) TIEMPO_TRANSPORTE_ESC <= 10; criterion = 0.739, statistic = 5.53
##          125)* weights = 23
##          124) TIEMPO_TRANSPORTE_ESC > 10
##          126)* weights = 22
##          123) CONDIC_VIDA_HOGAR > 2
##          127)* weights = 19
##      122) PERCAPITA > 143333.3
##          128) LUGAR_TRABAJO == {no trabajo}; criterion = 0.847, statistic = 9.143
##          129) INCAP <= 31; criterion = 0.79, statistic = 8.068
##          130)* weights = 9
##          129) INCAP > 31
##          131)* weights = 104
##          128) LUGAR_TRABAJO == {NA}
##          132)* weights = 35
##      113) TIEMPO_TRANSPORTE_ESC > 20
##          133)* weights = 416
##      112) PERCAPITA > 330083.3
##          134) INCRESOS_AUTOPERCIBIDOS_HOGAR <= 2; criterion = 1, statistic = 25.656
##          135) INCAP <= 30; criterion = 1, statistic = 24.26
##          136) ETNIA == {6}; criterion = 0.888, statistic = 9.81
##          137)* weights = 84
##          136) ETNIA == {1, 5}
##          138)* weights = 7
##          135) INCAP > 30
##          139) EDUCACION_PADRES <= 2; criterion = 0.944, statistic = 21.381
##          140) TRANSPORTE_ESCUELA == {escolar, público, Bicicleta}; criterion = 0.985, statistic
##          141)* weights = 524
##          140) TRANSPORTE_ESCUELA == {Carro, pie, Caballo, canoa, Otro, NA}
##          142) ETNIA == {4, 5, 6}; criterion = 0.862, statistic = 13.458
##          143) ETNIA == {4, 5}; criterion = 0.735, statistic = 11.332
##          144)* weights = 189
##          143) ETNIA == {6}
##          145)* weights = 2502
##          142) ETNIA == {1, 3}
##          146)* weights = 163
##          139) EDUCACION_PADRES > 2
##          147)* weights = 326
##          134) INCRESOS_AUTOPERCIBIDOS_HOGAR > 2
##          148)* weights = 326
##      111) UBICACION_ESCUELA > 2
##          149) ENFERMEDAD_CRONICA == {FALSE}; criterion = 1, statistic = 20.819
##          150) ESCUELA_OFICIAL == {SinSubstituto}; criterion = 0.999, statistic = 19.589
##          151) ETNIA == {1, 5}; criterion = 0.742, statistic = 8.385
##          152)* weights = 65

```

```
##          151) ETNIA == {6}
##          153) PERCAPITA <= 672611.1; criterion = 0.843, statistic = 6.29
##          154)* weights = 21
##          153) PERCAPITA > 672611.1
##          155)* weights = 10
##          150) ESCUELA_OFICIAL == {Oficial, conSubstituto}
##          156) INGRESOS_AUTOPERCIBIDOS_HOGAR <= 2; criterion = 0.959, statistic = 16.223
##          157) ETNIA == {2, 6}; criterion = 0.917, statistic = 15.979
##          158)* weights = 1293
##          157) ETNIA == {1, 5}
##          159) VIVE_CON_PADRE == {FALSE}; criterion = 0.934, statistic = 18.237
##          160)* weights = 153
##          159) VIVE_CON_PADRE == {TRUE, Muerto}
##          161) TRANSPORTE_ESCUELA == {Bicicleta, Caballo}; criterion = 0.995, statistic = 28.9
##          162)* weights = 9
##          161) TRANSPORTE_ESCUELA == {Carro, escolar, público, pie, canoa, Otro, NA}
##          163)* weights = 359
##          156) INGRESOS_AUTOPERCIBIDOS_HOGAR > 2
##          164)* weights = 33
##          149) ENFERMEDAD_CRONICA == {TRUE}
##          165)* weights = 36
```

```
test_pred <- predict(ctreeNiños, newdata = test)
colnames(test_pred) <- c('pred_Satisfaccion')
test_pred <- cbind(test_pred, test['SATISFACCION'])
```

```
cat_test_pred = lapply(test_pred/5.6, as.integer)
table(cat_test_pred)
```

```
##          SATISFACCION
## pred_Satisfaccion    0    1    2    3    4    5    6    7    8    9
##          3    0    1    5   27   28    9    7    0    0    0
##          4    2   20   56  449 1657   602  439  147   47    1
##          5    1    8   29  417 1531   846  737  324  138    8
##          6    0    1    1   21   51   14   73   51   48    3
```

```
train_pred <- predict(ctreeNiños, newdata = train)
colnames(train_pred) <- c('pred_Satisfaccion')
train_pred <- cbind(train_pred, train['SATISFACCION'])
```

```
cat_train_pred = lapply(train_pred/5.6, as.integer)
table(cat_train_pred)
```

```
##          SATISFACCION
## pred_Satisfaccion    0    1    2    3    4    5    6    7    8    9
##          3    1   13   19  108   77   15    8    1    0    0
##          4    2   61  153 1494 4940 1728 1403  438  113    5
##          5    0   18   69 1255 4362 2693 2322  983  403   27
##          6    0    1    0   40  157   63  237  175  108    8
```

### Calificación por “Feature Selection”

En lo consiguiente calculamos unas métricas para mejorar el arbol: Sacamos paso a paso una del los variables y miramos que impacto tiene cada.

**Resultados:** \* CANT\_PERSONAS\_HOGAR y EDAD tienen un impacto negativo en los datos de la

prueba y positivo en entrenamiento. \*\* Significa que estas variables producen “overfitting”. \* PERCAPITA, INCRESOS\_AUTOPERCIBIDOS\_HOGAR, UBICACION\_ESCUELA, EDUCACION\_PADRES, CONDIC\_VIDA\_HOGAR, ETNIA, ESCUELA\_OFICIAL, TRANSPORTE\_ESCUELA, EDUCACION\_PADRES, ACTIVIDAD\_ULT\_SEMANA, ENFERMEDAD\_CRONICA tienen un impacto estrictamente positivo. \* INCAP, LUGAR\_TRABAJO, TIEMPO\_TRANSPORTE\_ESC tienen a veces un impacto positivo y en otros casos producen overfitting \*\* Decidimos usar estas variables porque el impacto positivo es más grande que el negativo. \* HORAS\_TRABAJO y VALOR\_BECA no van a usar, sin embargo, tienen un impacto positivo. \*\* Sacamos VALOR\_BECA porque la correlación que hemos visto antes depende mucho de un valor atípico.

```
MSE_train <- mean((train_pred$SATISFACCION - train_pred$pred_Satisfaccion)^2)

MS_train <- mean(train_pred$SATISFACCION)^2

MSE_cat_train <- mean((cat_train_pred$SATISFACCION - cat_train_pred$pred_Satisfaccion)^2)

MS_cat_train <- mean(cat_train_pred$SATISFACCION)^2

MAE_train <- mean(abs(train_pred$SATISFACCION - train_pred$pred_Satisfaccion))

MAE_cat_train <- mean(abs(cat_train_pred$SATISFACCION - cat_train_pred$pred_Satisfaccion))

RMSE_cat_train <- sqrt(mean((cat_train_pred$SATISFACCION - cat_train_pred$pred_Satisfaccion)^2))
```

**Cálculo de métricas** Entrenamiento - MSE: {MSE\_train} - MS: {MS\_train} - MAE: {MAE\_train}  
Para las 10 categorías - MSE: {MSE\_cat\_train} - MS: {MS\_cat\_train} - MAE: {MAE\_cat\_train} - RMSE: {RMSE\_cat\_train}

```
MSE_test <- mean((test_pred$SATISFACCION - test_pred$pred_Satisfaccion)^2)

MSE_cat_test <- mean((cat_test_pred$SATISFACCION - cat_test_pred$pred_Satisfaccion)^2)

MAE_test <- mean(abs(test_pred$SATISFACCION - test_pred$pred_Satisfaccion))

MAE_cat_test <- mean(abs(cat_test_pred$SATISFACCION - cat_test_pred$pred_Satisfaccion))

RMSE_test <- sqrt(mean((cat_test_pred$SATISFACCION - cat_test_pred$pred_Satisfaccion)^2))
```

Prueba - MSE: {MSE\_test} - MAE: {MAE\_test} Para las 10 categorías - MSE: {MSE\_cat\_test} - MAE: {MAE\_cat\_test} - RMSE: {RMSE\_test}

**Matriz de confusión de los datos** Entrenamiento

```
# to factor
cat_train_pred$SATISFACCION = factor(cat_train_pred$SATISFACCION)
cat_train_pred$pred_Satisfaccion = factor(cat_train_pred$pred_Satisfaccion)

#reorder
cat_train_pred$pred_Satisfaccion = factor(cat_train_pred$pred_Satisfaccion,
                                          levels=c(0,1,2,3,4,5,6,7,8,9))

#create confusion matrix
confusionMatrix(table(cat_train_pred))

## Confusion Matrix and Statistics
```

```
##
##          SATISFACCION
## pred_Satisfaccion    0    1    2    3    4    5    6    7    8    9
##          0    0    0    0    0    0    0    0    0    0
##          1    0    0    0    0    0    0    0    0    0
##          2    0    0    0    0    0    0    0    0    0
##          3    1   13   19   108   77   15    8    1    0
##          4    2   61  153  1494  4940  1728  1403  438  113
##          5    0   18   69  1255  4362  2693  2322  983  403
##          6    0    1    0   40   157   63   237  175  108
##          7    0    0    0    0    0    0    0    0    0
##          8    0    0    0    0    0    0    0    0    0
##          9    0    0    0    0    0    0    0    0    0
##
## Overall Statistics
##
##          Accuracy : 0.3395
##          95% CI : (0.3334, 0.3456)
##          No Information Rate : 0.4058
##          P-Value [Acc > NIR] : 1
##
##          Kappa : 0.0771
##
## McNemar's Test P-Value : NA
##
## Statistics by Class:
##
##          Class: 0 Class: 1 Class: 2 Class: 3 Class: 4 Class: 5
## Sensitivity      0.000000 0.000000 0.00000 0.037280 0.5180 0.5986
## Specificity      1.000000 1.000000 1.00000 0.993496 0.6135 0.5032
## Pos Pred Value   NaN      NaN      NaN 0.446281 0.4779 0.2220
## Neg Pred Value   0.9998723 0.996043 0.98974 0.880084 0.6508 0.8411
## Prevalence       0.0001277 0.003957 0.01026 0.123277 0.4058 0.1914
## Detection Rate   0.0000000 0.000000 0.00000 0.004596 0.2102 0.1146
## Detection Prevalence 0.0000000 0.000000 0.00000 0.010298 0.4399 0.5163
## Balanced Accuracy 0.5000000 0.500000 0.50000 0.515388 0.5658 0.5509
##
##          Class: 6 Class: 7 Class: 8 Class: 9
## Sensitivity      0.05970 0.00000 0.00000 0.000000
## Specificity      0.97174 1.00000 1.00000 1.000000
## Pos Pred Value   0.30038      NaN      NaN      NaN
## Neg Pred Value   0.83563 0.93204 0.97345 0.998298
## Prevalence       0.16894 0.06796 0.02655 0.001702
## Detection Rate   0.01009 0.00000 0.00000 0.000000
## Detection Prevalence 0.03357 0.00000 0.00000 0.000000
## Balanced Accuracy 0.51572 0.50000 0.50000 0.500000
```

Prueba

```
# to factor
cat_test_pred$SATISFACCION = factor(cat_test_pred$SATISFACCION)
cat_test_pred$pred_Satisfaccion = factor(cat_test_pred$pred_Satisfaccion)

#reorder
cat_test_pred$SATISFACCION = factor(cat_test_pred$SATISFACCION,
                                     levels=c(0,1,2,3,4,5,6,7,8,9))
```

```
cat_test_pred$pred_Satisfaccion = factor(cat_test_pred$pred_Satisfaccion,
                                          levels=c(0,1,2,3,4,5,6,7,8,9))
```

```
#create confusion matrix
```

```
confusionMatrix(table(cat_test_pred))
```

```
## Confusion Matrix and Statistics
```

```
##
```

```
##          SATISFACCION
```

## pred_Satisfaccion	0	1	2	3	4	5	6	7	8	9
## 0	0	0	0	0	0	0	0	0	0	0
## 1	0	0	0	0	0	0	0	0	0	0
## 2	0	0	0	0	0	0	0	0	0	0
## 3	0	1	5	27	28	9	7	0	0	0
## 4	2	20	56	449	1657	602	439	147	47	1
## 5	1	8	29	417	1531	846	737	324	138	8
## 6	0	1	1	21	51	14	73	51	48	3
## 7	0	0	0	0	0	0	0	0	0	0
## 8	0	0	0	0	0	0	0	0	0	0
## 9	0	0	0	0	0	0	0	0	0	0

```
##
```

```
## Overall Statistics
```

```
##
```

```
##          Accuracy : 0.3338
```

```
##          95% CI : (0.3233, 0.3444)
```

```
##          No Information Rate : 0.4189
```

```
##          P-Value [Acc > NIR] : 1
```

```
##
```

```
##          Kappa : 0.0643
```

```
##
```

```
##          McNemar's Test P-Value : NA
```

```
##
```

```
## Statistics by Class:
```

```
##
```

```
##          Class: 0 Class: 1 Class: 2 Class: 3 Class: 4 Class: 5
```

```
## Sensitivity      0.0000000 0.000000 0.000000 0.029540 0.5072 0.5751
```

```
## Specificity      1.0000000 1.000000 1.000000 0.992738 0.6110 0.4954
```

```
## Pos Pred Value   NaN      NaN      NaN 0.350649 0.4845 0.2095
```

```
## Neg Pred Value   0.9996153 0.996153 0.98833 0.885133 0.6323 0.8338
```

```
## Prevalence       0.0003847 0.003847 0.01167 0.117195 0.4189 0.1886
```

```
## Detection Rate   0.0000000 0.000000 0.000000 0.003462 0.2125 0.1085
```

```
## Detection Prevalence 0.0000000 0.000000 0.000000 0.009873 0.4385 0.5179
```

```
## Balanced Accuracy 0.5000000 0.500000 0.50000 0.511139 0.5591 0.5353
```

```
##          Class: 6 Class: 7 Class: 8 Class: 9
```

```
## Sensitivity      0.05812 0.00000 0.00000 0.000000
```

```
## Specificity      0.97096 1.00000 1.00000 1.000000
```

```
## Pos Pred Value   0.27757      NaN      NaN      NaN
```

```
## Neg Pred Value   0.84302 0.93307 0.97012 0.998461
```

```
## Prevalence       0.16105 0.06693 0.02988 0.001539
```

```
## Detection Rate   0.00936 0.00000 0.00000 0.000000
```

```
## Detection Prevalence 0.03372 0.00000 0.00000 0.000000
```

```
## Balanced Accuracy 0.51454 0.50000 0.50000 0.500000
```

```
levels(cat_test_pred$SATISFACCION)
```

```
## [1] "0" "1" "2" "3" "4" "5" "6" "7" "8" "9"
```

## Conclusiones

## Recomendaciones

## Referencias

- [1] Ramírez Pérez, Mauricio; Lee Maturana, Sau-Lyn (2012). Factores asociados a la satisfacción vital en adultos mayores de 60 años. Polis (Santiago), 11(33), 407–428. doi:10.4067/s0718-65682012000300020
- [2] Kutubaeva RZh (2019) Analysis of life satisfaction of the elderly population on the example of Sweden, Austria and Germany. Population and Economics 3(3): 102-116. <https://doi.org/10.3897/popecon.3.e47192>
- [3] Palmore, E., Luikart, C. (1972). Health and Social Factors Related to Life Satisfaction. Journal of Health and Social Behavior, 13(1), 68–80. doi: 10.2307/2136974
- [4] Naidu, Aditi (2009). Factors affecting patient satisfaction and healthcare quality. International Journal of Health Care Quality Assurance, 22(4), 366–381. doi:10.1108/09526860910964834
- [5] ROBLES-GARCIA, Monica et al. Variables relacionadas con la satisfaccion laboral: un estudio transversal a partir del modelo EFQM. Gac Sanit [online]. 2005, vol.19, n.2, pp.127-134. ISSN 0213-9111
- [6] Booth, Jaime; Ayers, Stephanie L.; and Marsiglia, Flavio F. (2012) "Perceived Neighborhood Safety and Psychological Distress: Exploring Protective Factors," The Journal of Sociology & Social Welfare: Vol. 39 : Iss. 4 , Article 8. Available at: <https://scholarworks.wmich.edu/jssw/vol39/iss4/>
- [7] <https://ourworldindata.org/happiness-and-life-satisfaction>